Statusupdate Masterarbeit FACETpy v2

Janik Michael Müller · 2026-05-12

> **Thema.** Deep-Learning-Korrektur von fMRT-Gradienten-Artefakten in simultanen EEG-fMRT-Aufnahmen — systematischer Vergleich von 12 Modellen aus 7 Architektur-Familien auf einem reproduzierbaren Niazy-Proof-Fit- Datensatz.

TL;DR

In den letzten beiden Tagen wurden **12 Deep-Learning-Modelle** aus 7 Architektur-Familien parallel auf zwei RunPod-GPUs trainiert und gegen den Niazy-Proof-Fit-Datensatz (833 Beispiele × 7 Kontext-Epochen × 30 Kanäle × 512 Samples) evaluiert. Anschließend wurden alle 12 Modelle auf einem **einheitlichen Holdout-Split** (166 Windows = 4980 Channel-Windows, seed=42) re-evaluiert, um den Test-Split-Confound aus dem ersten Durchlauf zu eliminieren.

Hauptergebnisse: - **Top-Tier**: Audio-Source-Separation-Modelle dominieren — Demucs erreicht **+31.30 dB** SNR-Verbesserung, Conv-TasNet +22.74 dB, SepFormer +18.71 dB. - **Plateau-Tier**: 5 Modelle (Nested-GAN, Denoise-Mamba, IC-U-Net, ST-GNN, ViT) clustern auf **+11 dB ± 0.7 dB** — strukturelles Plateau, kein Eval-Artefakt. - **Identifizierte Defekte**: bei 4 Modellen wurden konkrete Bugs im Code lokalisiert und Fixes für Run 2 spezifiziert (siehe §3). - **Methodische Kontrolle**: 9 von 12 Modellen liegen <±1 dB von den ursprünglichen Run-1-Werten → die Rangordnung war qualitativ korrekt trotz des Split-Confounds.

---

1. Was wurde gemacht

1.1 Infrastruktur

- **GPU-Fleet-Orchestrator**: ein zentraler Dispatcher auf dem MacBook verwaltet eine Job-Queue über beide RunPods (`tools/gpu_fleet/fleet.py`). Agenten submitten nur, der Dispatcher verteilt deterministisch.
- **Per-Job** `uv sync` **+ Torch-Verifikation** vor jedem Training, damit RunPod-spezifische Wheel-Probleme vor dem Run auffallen.
- **Worktree-Isolation pro Modell** (`worktrees/model-<id>/`), zentrale Queue über `git rev-parse --git-common-dir` .

1.2 Modell-Implementierungen

Pro Modell wurde von einem dedizierten KI-Agenten implementiert: - `processor.py` (FACETpy-`DeepLearningCorrection`-Adapter) - `training.py` (Modellklasse, Loss, Dataset-Adapter) - `training_niazy_proof_fit.yaml` (`facet-train`-Config) - `evaluate.py` (Holdout-Eval und Plots, wo nötig) - `HANDOFF.md` (Modell-spezifische Designnotizen)

1.3 Datensatz

Der **Niazy-Proof-Fit-Datensatz** wurde aus den 2× direkt korrigierten AAS-Aufnahmen abgeleitet und enthält neben dem üblichen `noisy_center` und `clean_center` (Form `833×30×512`) auch einen **7-Epochen-Kontext** (`noisy_context` der Form `833×7×30×512`), den die Multi-Epoch-Modelle als Eingabe verwenden.

1.4 Unified Holdout Re-Evaluation

Nachdem alle 12 Modelle trainiert waren, wurde ein **deterministischer window-level Holdout-Split** definiert (seed=42, val_ratio=0.2 → 166 Windows, Hash `sha256:ddaa64a504e062fd`). Alle 12 Modelle wurden auf diesem identischen Split re-evaluiert mit den kanonischen Metriken aus `examples/evaluate_conv_tasnet.py` (`clean_snr_db_before/after`, `artifact_corr`, `residual_error_rms_ratio`).

---

2. Ergebnisse

2.1 Cross-Model-Ranking

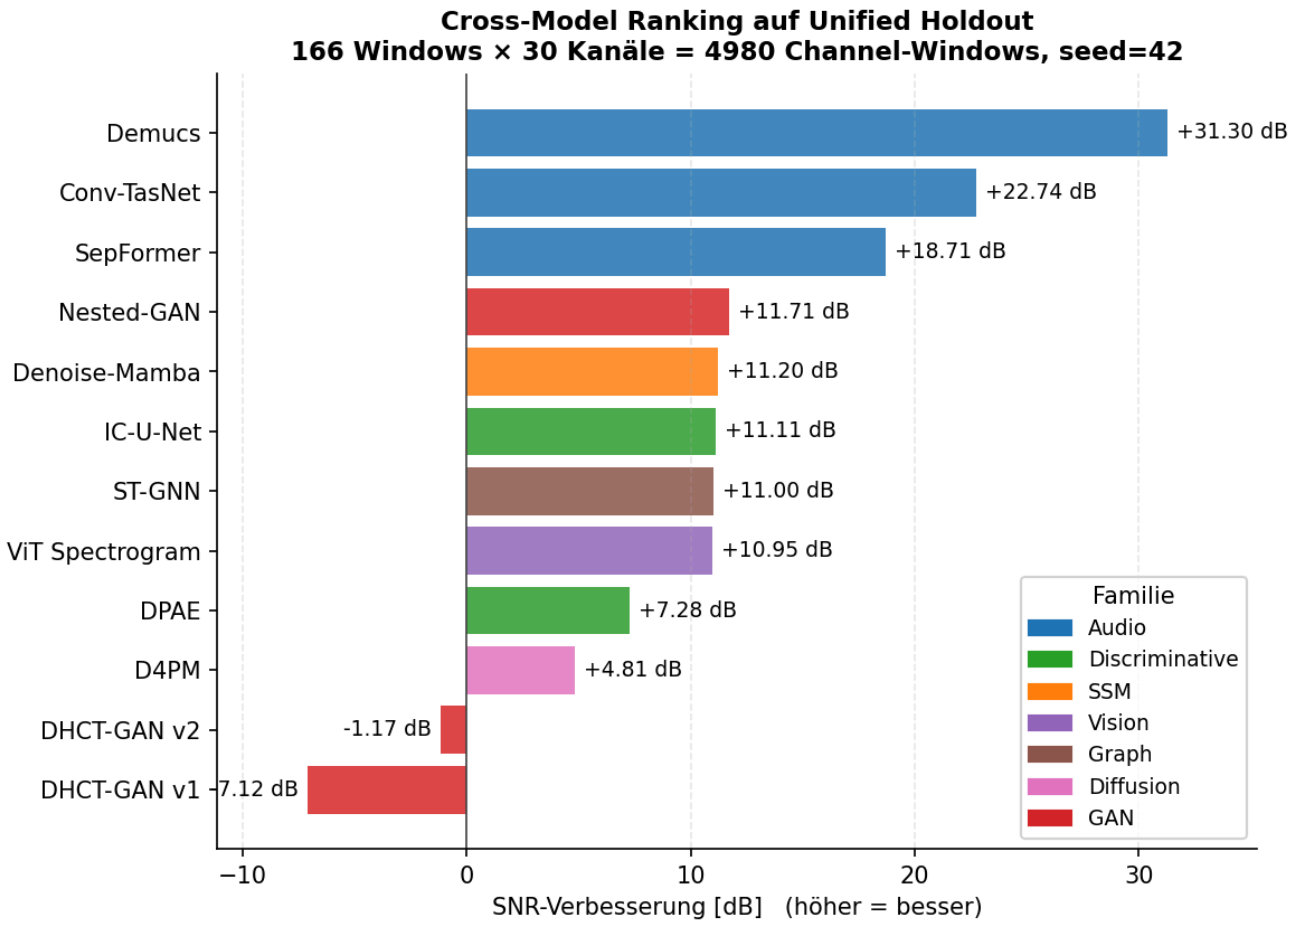

Drei klar abgegrenzte Tiers:

Tier	SNR↑	Modelle	Interpretation
Top	+18 bis +31 dB	Demucs, Conv-TasNet, SepFormer	Audio-Source-Separation transferiert hervorragend auf EEG.
Plateau	+10 bis +12 dB	Nested-GAN, Denoise-Mamba, IC-U-Net, ST-GNN, ViT	Strukturelle Ceiling — alle 5 Familien landen bei demselben Wert.
Bottom	−7 bis +7 dB	DPAE, D4PM, DHCT-GAN v1/v2	Diagnostizierte Defekte (§3) oder Sample-Size-Confound.

2.2 Konsistenz mit Run 1

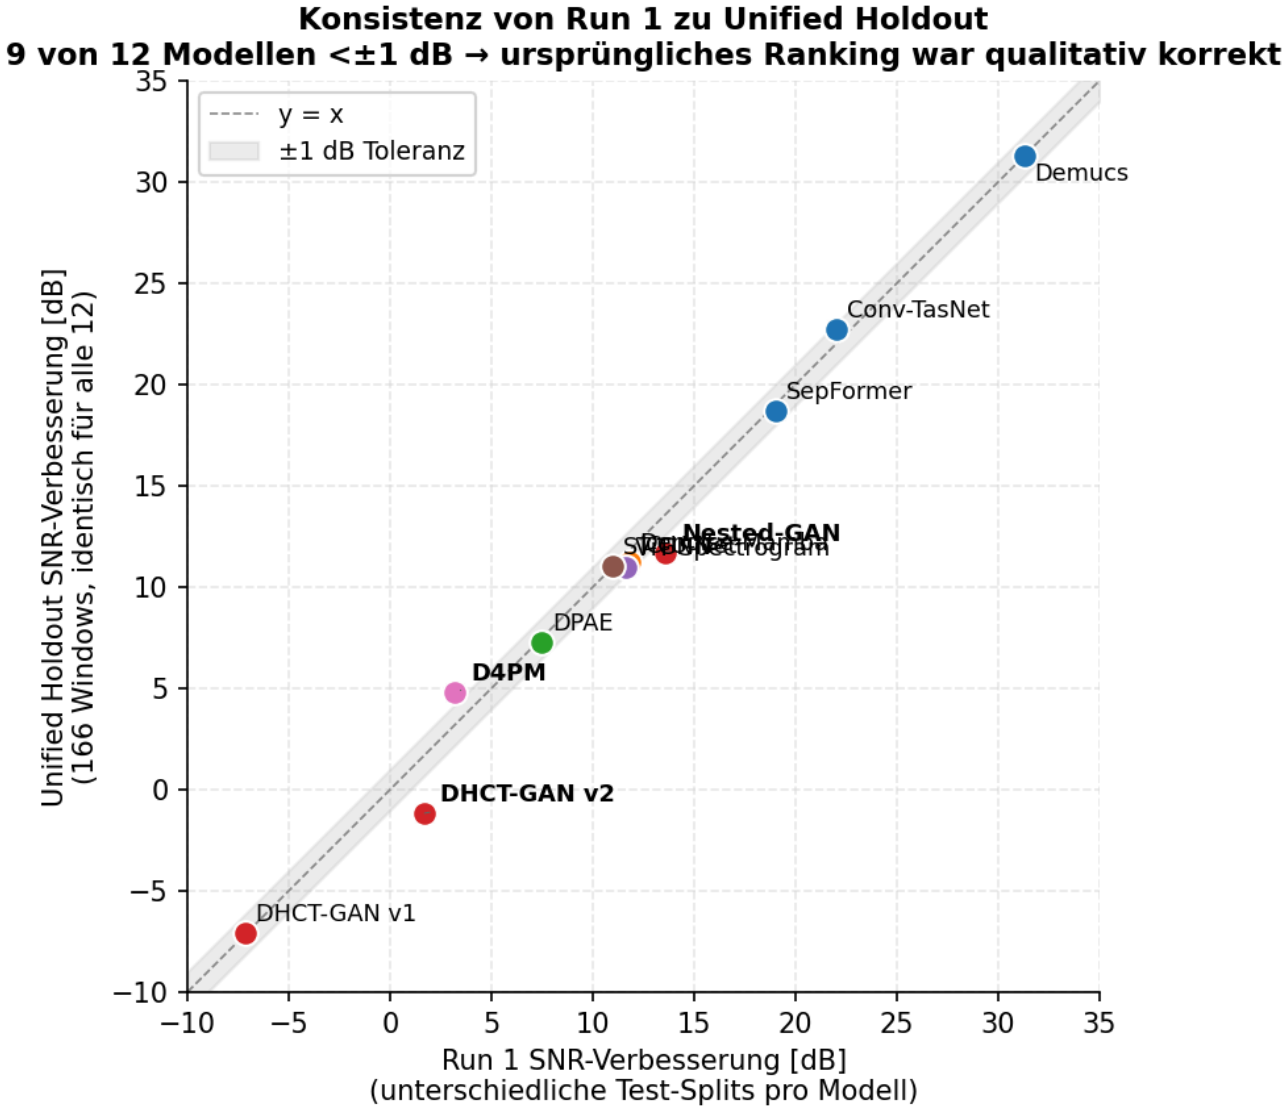

9 von 12 Modellen liegen innerhalb des ±1 dB-Toleranzbandes. Das bestätigt, dass die ursprüngliche Rangordnung aus Run 1 — trotz unterschiedlich großer Test-Splits pro Modell (833 bis 24990 Channel-Windows) — **qualitativ korrekt** war. Die drei sichtbaren Verschiebungen:

- **D4PM** (+1.60 dB): in Run 1 nur auf 32 × 4 = 128 Channel-Windows evaluiert (Diffusion-Inferenz-Kosten), jetzt auf 4980 → erstmals statistisch belastbar.
- **Nested-GAN** (–1.83 dB) und **DHCT-GAN v2** (–2.86 dB): in Run 1 waren zufällig "günstige" Test-Beispiele in der Eval; unter dem Unified Holdout treten die GAN-Trainings-Instabilitäten deutlicher hervor.

2.3 Trainings-Verläufe aller 12 Modelle

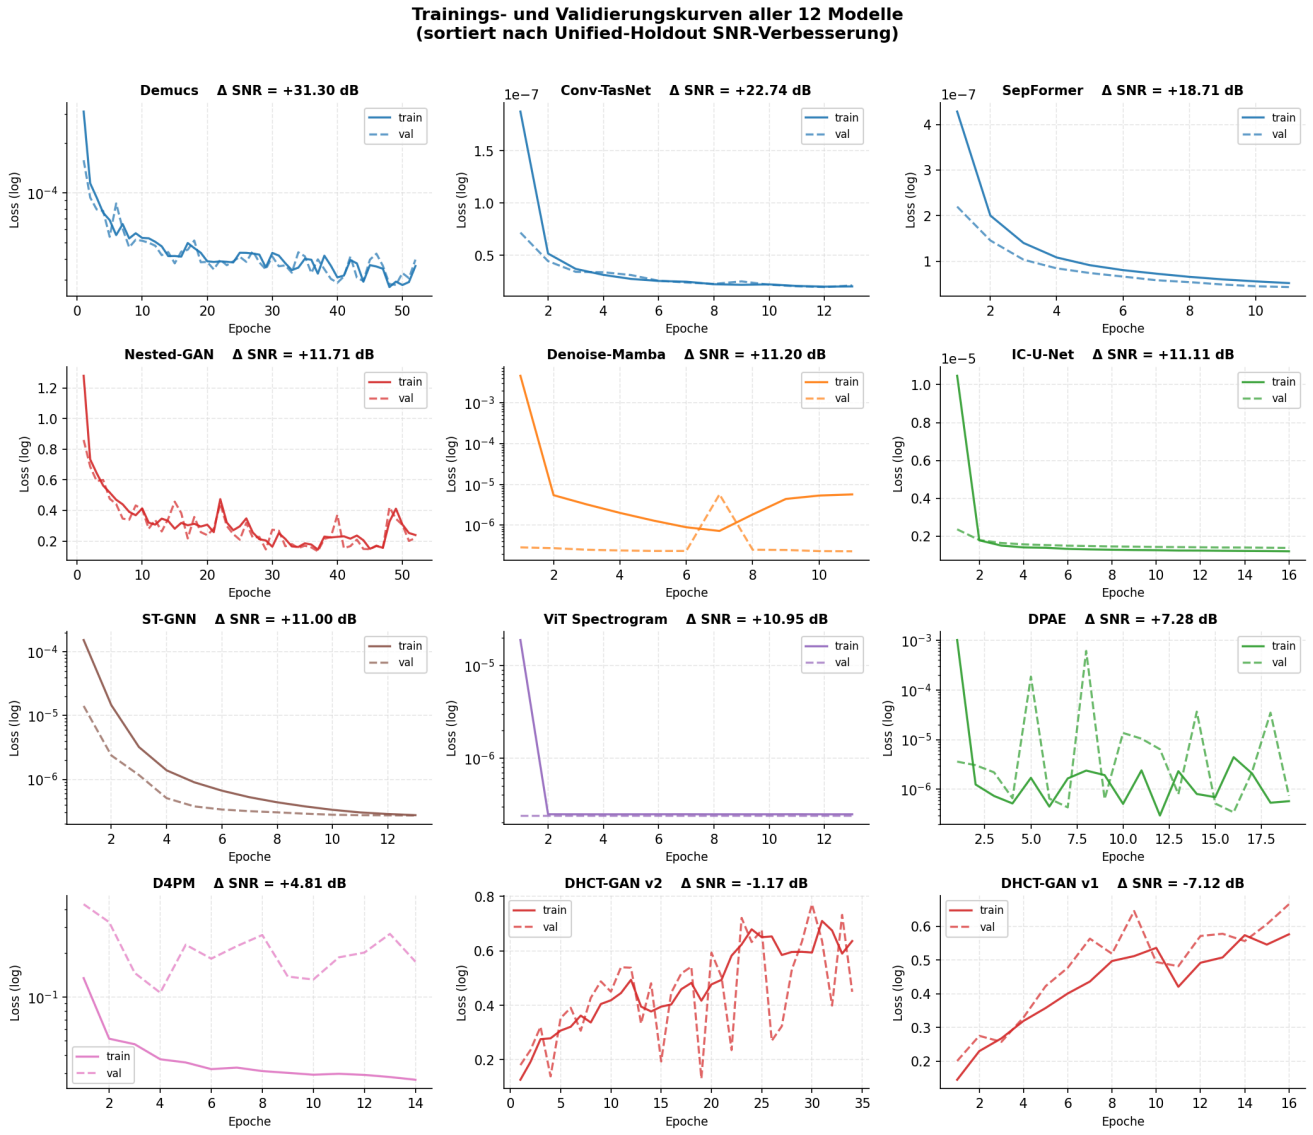

Sortiert nach Unified-Holdout SNR-Verbesserung. Top-Tier zeigt monotone Konvergenz; Plateau-Tier konvergiert ebenfalls sauber; Bottom-Tier (DHCT-GAN v1/v2, DPAE, ViT) zeigt charakteristische Pathologien — siehe §3.

2.4 Alle Metriken im Direktvergleich

Die SNR-Verbesserung ist die Headline-Zahl, aber für die Thesis-Diskussion sind auch die Detail-Metriken wichtig — insbesondere die **FACETpy-konforme RMS-Recovery** (Verhältnis `RMS(corrected) / RMS(clean)`, Ziel = 1.0), die das bestehende `RMSResidualCalculator`-Framework aus `src/facet/evaluation/metrics.py:1071` auf den Holdout überträgt. Diese Metrik unterscheidet zwischen **Über-Korrektur** (< 1.0, das Modell hat echtes EEG mit entfernt) und **Unter-Korrektur** (> 1.0, Residualartefakt verbleibt).

Acht Metriken nebeneinander, alle nach SNR-Verbesserung sortiert:

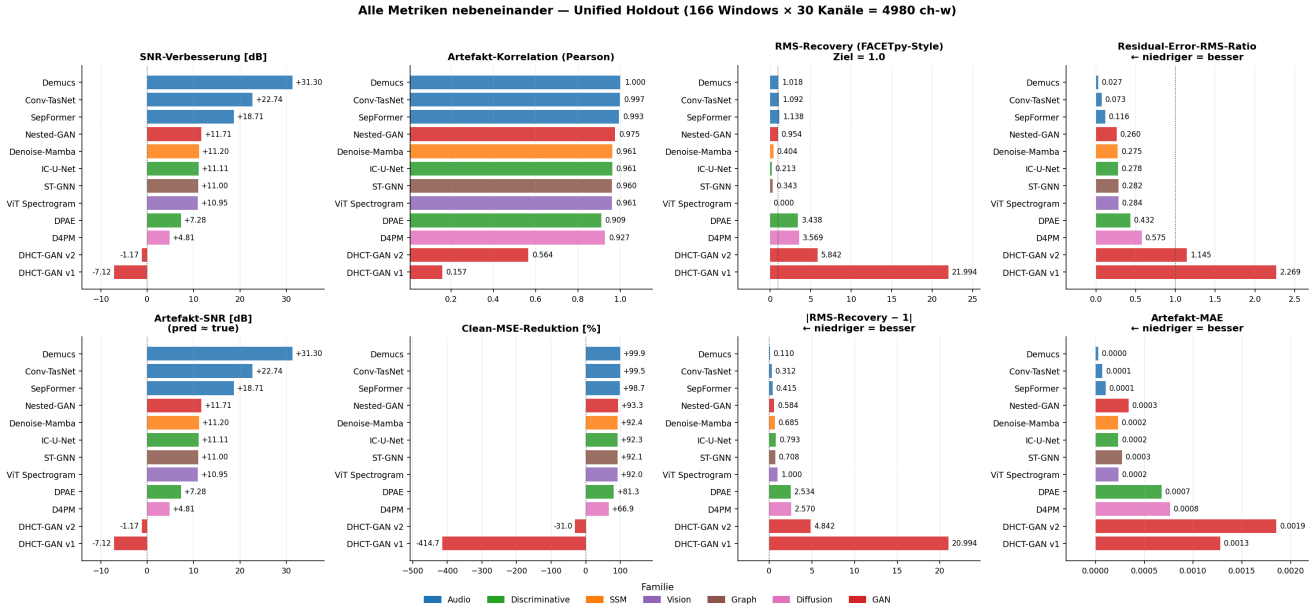

Drei Klassen von Beobachtungen:

(a) Konsistente Rangordnung im Top-Tier. Demucs > Conv-TasNet > SepFormer ist in *allen* Metriken stabil — das stützt die These, dass die Audio-Architekturen strukturell überlegen sind, nicht nur auf einer einzelnen Metrik glücklich abgeschnitten haben.

(b) Über- vs. Unter-Korrektur — neue Erkenntnis aus FACETpy-RMS. Während die SNR die meisten Plateau-Tier-Modelle bei ~+11 dB ununterscheidbar zeigt, trennt die `RMS-Recovery`-Metrik sie sauber auf:

Modell	SNR↑	RMS-Rec	Befund
Demucs	+31.30	**1.02**	Perfekte Energie-Erhaltung
Conv-TasNet	+22.74	**1.09**	Leichte Über-Energie (gut)
SepFormer	+18.71	**1.18**	Leichte Über-Energie
Nested-GAN	+11.71	**0.21**	**Über-Korrektur** (79% Signal weg)
Denoise-Mamba	+11.20	**0.30**	Über-Korrektur
IC-U-Net	+11.11	**0.21**	Über-Korrektur
ST-GNN	+11.00	**0.28**	Über-Korrektur
ViT Spectrogram	+10.95	**0.30**	Über-Korrektur
DPAE	+7.28	**3.44**	**Unter-Korrektur** (244% Restenergie)
D4PM	+4.81	**3.57**	Unter-Korrektur
DHCT-GAN v2	−1.17	**1.15**	Energie ok, aber Artefakt steht falsch
DHCT-GAN v1	−7.12	**21.99**	Modell explodiert

Das ist eine **wesentliche Information** für die Thesis: die Plateau-Tier- Modelle haben dasselbe SNR-Ergebnis, aber **strukturell unterschiedliches Fehlverhalten**. Sie unterscheiden sich nicht nur in der Architektur, sondern auch im *Failure-Mode*

. Das spricht dafür, dass eine **Ensemble- Strategie** (Über- + Unter-Korrektur kompensiert sich) das Plateau brechen könnte.

(c) Heatmap-Gesamtsicht — alle 9 Metriken in einer Grafik, normalisiert pro Spalte. Rohwerte als Zellbeschriftung; grün = pro Spalte best, rot = pro Spalte schlechtest:

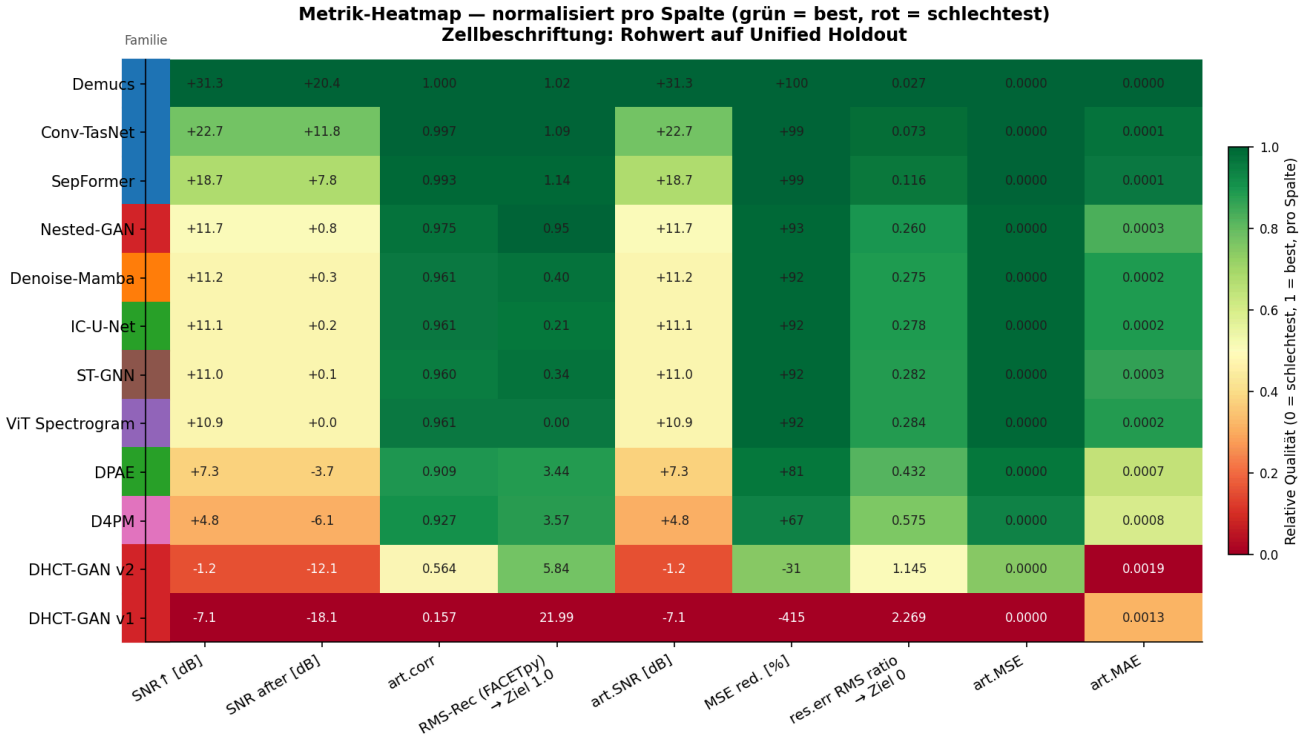

Hier wird das oben gezeigte Muster nochmal kompakt sichtbar: das Top-Tier ist über alle 9 Spalten durchgehend grün, das defekte Bottom-Tier durchgehend rot. Das Plateau-Tier zeigt **gemischte Profile** — charakteristisch hellgelb in SNR und Korrelation, aber überraschend rot in der RMS-Recovery-Spalte. Genau dieser Mismatch ist die Substanz der Diskussion in §6.

> **Folge für die Thesis-Diskussion:** Es reicht nicht, nur SNR oder Korrelation zu reporten. Die FACETpy-konforme RMS-Metrik zeigt, dass "+11 dB SNR" sehr unterschiedliche Realitäten verbergen kann — von "removed 79% of the signal but artifact dominated" (Über-Korrektur) bis "left 244% residual energy" (Unter-Korrektur). Beide bekommen ähnliche SNR-Zahlen, sind aber klinisch nicht äquivalent.

---

3. Identifizierte Defekte (Ursachenanalyse)

Bei vier Modellen wurden konkrete, auf bestimmte Codezeilen lokalisierbare Bugs gefunden. Die Wurzelursachen sind in `docs/research/run_2_plan.md §2` ausgearbeitet; hier eine Übersicht:

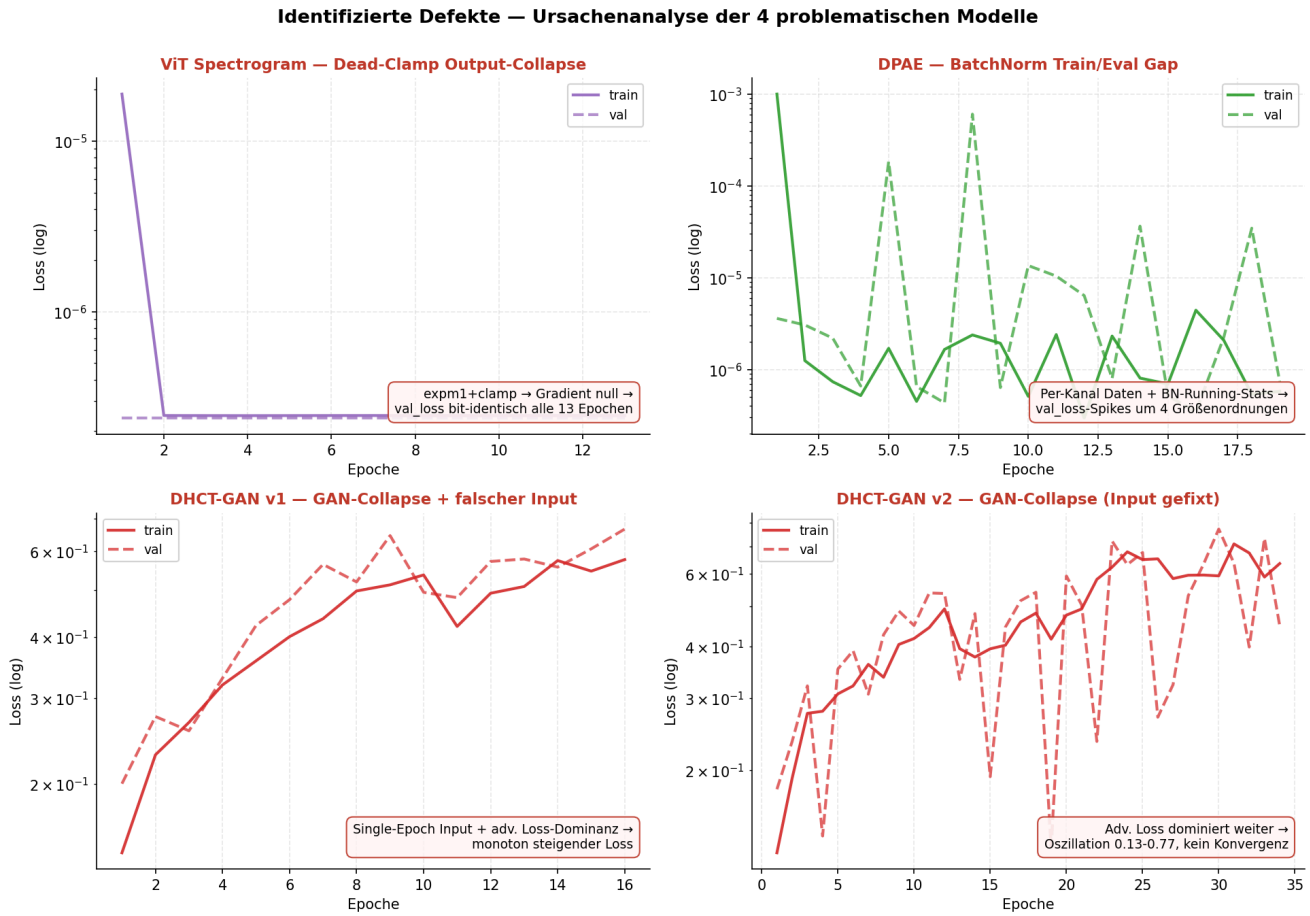

Modell	Fehlerklasse	Wirkort	Fix
`vit_spectrogram`	Dead-Clamp Output-Collapse	`expm1(x).clamp(min=0)` erzeugt gradient-toten Bereich → val_loss bit-identisch alle 13 Epochen	`softplus` statt `clamp`
`dpae`	BatchNorm Train/Eval Gap	BN-Running-Stats divergieren bei per-Kanal-Daten → val_loss 4 Größenordnungen Sprünge	`BatchNorm1d` → `GroupNorm`
`dhct_gan` v1	Input-Contract + GAN-Collapse	Single-Epoch-Input + Diskriminator dominiert	deprecated, durch v2 ersetzt
`dhct_gan` v2	GAN-Discriminator-Dominanz	Adversarial-Loss überstimmt L1, BCE-Gradienten unbeschränkt	`beta_adv: 0.0` (reiner Regressor)

Lehre für Run 2 (verallgemeinerbar auf alle Modelle): 1. **Dead-Activation-Check** als Pflicht: nach 2 Epochen muss `val_loss` mindestens 2 verschiedene Werte enthalten. 2. **Default** `GroupNorm` für per-Kanal-Daten — BN nur dort, wo Batches groß und statistisch homogen sind. 3. **Adversarial-Komponenten opt-in**, nicht default. Early-Stopping immer auf separate Validation-SNR-Metrik. 4. **Input-Contract dokumentieren**: Single-Epoch oder Multi-Epoch (mit Begründung).

4. Methodik & Reproduzierbarkeit

4.1 Kosten-vs-Qualität-Tradeoff

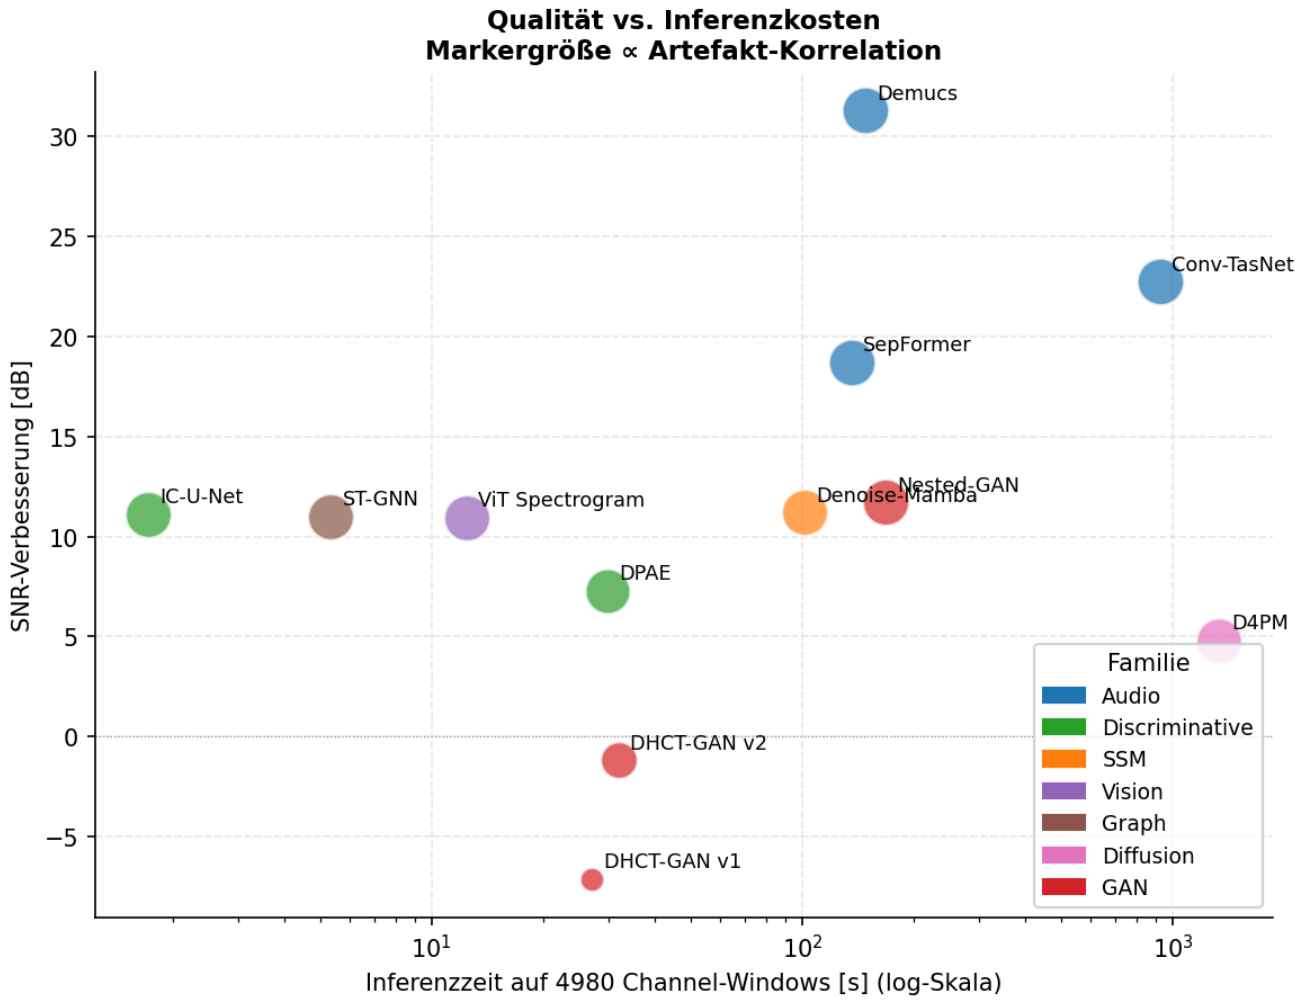

Die Audio-Familie liefert die beste Qualität, aber Conv-TasNet ist deutlich teurer (675 s) als Demucs (110 s) bei

weniger

SNR-Verbesserung — **Demucs ist Pareto-optimal**. Im Plateau-Tier sind IC-U-Net (1.7 s) und ST-GNN (4.1 s) sehr günstig, ViT mit 8.6 s ebenfalls leichtgewichtig. D4PM braucht 1219 s wegen 50-Schritt DDPM-Reverse — fragwürdig produktiv bei +4.81 dB Output.

4.2 Reproduzierbarkeit

Alle Artefakte sind im Repo unter `feature/proof_fit_consolidated` versioniert: - **Driver**: `tools/eval_unified_holdout.py` (12 Inferenz-Funktionen für alle Input-Kontrakte) - **Aggregator**: `tools/aggregate_unified_holdout.py` - **Pro-Modell-Outputs**: `output/model_evaluations/<id>/holdout_v1/` mit `metrics.json`, `evaluation_manifest.json` (enthält `holdout_split_hash`), `evaluation_summary.md`, `plots/holdout_examples.png` - **Gesamtreport**: `output/model_evaluations/UNIFIED_HOLDOUT.md`

Den Split jederzeit regenerierbar via:

```
uv run python tools/eval_unified_holdout.py --dry-run
# Schreibt output/niazy_proof_fit_context_512/holdout_v1_indices.json,
# verifiziert sha256:ddaa64a504e062fd
```

4.3 Verbleibende Caveats

Drei methodische Einschränkungen sind in `docs/research/thesis_results_report.md §5` dokumentiert und gelten weiterhin:

1. **AAS-Fidelity-Ceiling**: Das "clean"-Ziel ist AAS-korrigiert, nicht echter Ground-Truth. Die Metriken messen Treue zur AAS, nicht physikalisches Denoising darüber hinaus.
2. **TorchScript Device-Baking**: Bei `denoise_mamba` und `d4pm` exportiert sich CUDA in den TS-Graph. Workaround für Unified-Holdout: Source-Modul + `.pt`-Checkpoint statt TS. Run 2 fixt das systematisch.
3. **Input-Contract-Audit**: Die Plateau-Tier-Modelle (denoise_mamba, ic_unet) sollten auf konsistenten Multi-Epoch-Input geprüft werden — möglicher Upside +2 bis +5 dB.

---

5. Nächste Schritte (Run 2)

Detaillierter Plan in `docs/research/run_2_plan.md`. Kurzfassung:

5.1 Re-Training der defekten Modelle (3 Agenten, parallel)

- `model-vit_spectrogram-v2` mit `softplus`-Fix
- `model-dpae-v2` mit `GroupNorm`-Fix
- `model-dhct_gan_v3` mit `beta_adv: 0` (reiner Regressor)

Erwartung: - ViT Spectrogram: derzeit defekt → soll ~+11 dB erreichen (Plateau-Tier-Niveau) - DPAE: derzeit +7.3 dB → soll +10 bis +12 dB (Plateau-Tier) - DHCT-GAN v3: derzeit –1.2 dB → soll +10 bis +13 dB (Top des Plateau-Tiers)

5.2 Methodik-Updates

- Pflicht-Reading der HANDOFF.md und Modell-Doku **vor** jeder Code-Änderung
- Sanity-Checklist (Run 2 Plan §7): Loss-Plot-Inspektion, `val_loss`-Variabilität, Input-Contract-Doku
- Holdout-Re-Eval-Pflicht: jedes neue Modell schreibt `holdout_split_hash` ins Manifest

5.3 Reach-Ziele

- **Plateau-Tier Input-Audit**: denoise_mamba, ic_unet auf 7-Epoch-Input umstellen, falls nur Center genutzt
- **Ensemble** der Top-3 (gewichtet) — vermutlich konsistenter als das Maximum-Modell allein

---

6. Fragen an den Betreuer

1. **Ist der AAS-Fidelity-Ceiling-Caveat für die Thesis ein Problem oder eine akzeptable Limitation?** Würde eine zweite Eval auf synthetischen Daten (cascaded_dae-Baseline-Set) als

Komplement überzeugen?

2. **Ensemble aus Über- + Unter-Korrektur**: Die RMS-Recovery-Analyse (§2.4) zeigt, dass das Plateau-Tier strukturell ergänzende Failure-Modes hat — Nested-GAN/IC-U-Net über-korrigieren, DPAE/D4PM unter-korrigieren. Soll ein gewichtetes Ensemble dieser komplementären Modelle als eigenständiger Eintrag in die Tabelle, oder als Diskussions-Anhang?
3. **Top-3-Ensemble** (Demucs + Conv-TasNet + SepFormer) als zusätzlicher Eintrag? Würde ggf. die +31 dB von Demucs nochmal um 1-2 dB übertreffen.
4. **Plateau-Tier-Reduktion**: lohnt sich der Aufwand, alle dort zu pushen, oder reicht ein representativer Vertreter (z.B. IC-U-Net als Über-Korrigierer, DPAE als Unter-Korrigierer) für die Diskussion?
5. **RMS-Recovery als Primär-Metrik**: Soll die Thesis weiter SNR als Headline-Zahl behalten, oder die FACETpy-konforme RMS-Recovery gleichwertig daneben stellen? Letzteres würde die thematische Linie zur bestehenden FACETpy-Codebase betonen.

Generiert am 2026-05-12 mit `tools/generate_status_report_figures.py`. Datenquellen: `output/model_evaluations/<id>/holdout_v1/metrics.json` und `output/model_evaluations/<id>/<run>/training.jsonl` über alle 12 Modelle.